

ŁĄCZNIK

Marta chce pomóc. Od czego zacząć?

Chce wesprzeć seniorów
w swojej społeczności.
Szuka pomysłu, który im pomoże.

Inteligentne narzędzie dla
Małopolskiego Hubu Innowacji Społecznych

Historia przykładowa. Marta jest fikcyjną bohaterką.



Marta zaczyna od wiedzy. Sprawdza, co już pomaga seniorom

BLISKO

200

innowacji w portfolio ROPS



Analizuje zasobnik wiedzy

- 01 Jakie problemy rozwiązują innowacje?
- 02 Dla kogo powstały i jak działają?
- 03 Co może wykorzystać u siebie?

Opisy innowacji i materiały źródłowe dają Marcie punkt odniesienia.

Marta opisuje potrzebę. Łącznik dobiera pasujące innowacje



WŁASNYMI SŁOWAMI

„Seniorzy mają trudność z dotarciem po pomoc. Chcemy docierać do nich w domach”.

Marta analizuje propozycje i źródła.
Wybiera inspiracje do własnego pomysłu.

PRZYKŁADOWA PROPOZYCJA

Mobilne centrum pomocy dla osób starszych

Dlaczego pasuje

Wsparcie w domu seniora.
Dostęp do usług przy ograniczonej mobilności.

Uzasadnienie + opis innowacji + źródło

Z inspiracji powstaje własny pomysł. Marta tworzy go w kreatorze



Jej pomysł: „Sąsiedzkie wsparcie seniorów”. AI pomaga dopracować założenia.

01

Fiszka

Dla kogo powstaje pomysł?
Co zmienia w codzienności?

02

Canva

Jakie są założenia?
Co trzeba sprawdzić?

03

Wniosek

Jak opisać pomysł
w konkretnym naborze?

Marta opisuje własną innowację, planuje test i przygotowuje się do naboru.

Marta znajduje testerów. Ich opinie pomagają poprawić pomysł



Sprawdza pomysł z odbiorcami

- 1 Dobiera osoby**
AI szuka pasujących doświadczeń i zasobów.
- 2 Zaprasza do udziału**
Ogłoszenie zbiera zgłoszenia uczestników.
- 3 Zbiera opinie**
Oceny i usprawnienia pomagają poprawić pomysł.



ROPS jest w tej rozmowie

Wątki wiadomości
łączą użytkownika
z pracownikiem Hubu.

Pomysł Marty może pomóc dalej. Każda gmina ma jednak inne zasoby

SCENARIUSZ ROZWOJU

**„Chcemy wdrożyć
ten pomysł u nas.
Mamy inny zespół
i budżet”.**

Kolejna gmina korzysta
z doświadczenia Marty.

01

Zasoby gminy

Zespół, czas i dostępny budżet.

02

Lokalne dopasowanie

Zakres działań, braki i potrzebne wsparcie.

03

Plan wdrożenia

Propozycja kroków do konsultacji z Hubem.



Jedna platforma. Wspólna podstawa dla wielu gmin.

Wspólne zaplecze dla wiedzy, pomysłów i współpracy między gminami.



Klucze AI pozostają na backendzie.

API umożliwia dalsze integracje.

Dziś płacimy za interpretację. Ranking i uzasadnienia liczy aplikacja



1–4

wywołania AI na potrzebę

Brak wyników lub więcej niż 5 dopasowań → do 3 pytań.
Każda odpowiedź ponownie wysyła opis i dotychczasową historię do Qwen.

Biblioteka ROPS nie trafia do modelu przy każdym zapytaniu — to już obniża koszt

Jev rozpoznaje potrzebę. Wyszukiwarka dobiera dowody i rozwiązania



POZA SESJĄ

Biblioteka ROPS → weryfikacja i wersjonowanie opisów → tagi / indeks / wektory

Nie każdy etap potrzebuje modelu językowego

Moduł	Kiedy uruchamiamy	API / 100 tys. sesji
Jev: klasyfikacja	1,5 × 800 tokenów wejścia / sesję	21,17 zł
Wyszukiwanie lokalne	Przy każdym kroku; bez zewnętrznego AI	w hostingu
Awaryjna interpretacja LLM	10% kroków × 1 200 in / 180 out	12,10 zł
Uzasadnienie LLM	20% sesji × 1 200 in / 180 out	16,13 zł
Opcja: embedding zapytania	1,5 × 200 tokenów / sesję	2,52 zł
Opcja: reranking top 20	25% kroków × 9 000 tokenów	28,35 zł
Razem wariant hybrydowy	Jev + wyszukiwanie + opcje semantyczne	80,26 zł

Wariant prostszy: Jev + wyszukiwanie lokalne = 49,39 zł / 100 tys. sesji.
Dla katalogu około 200 innowacji zaczniemy bez płatnego rerankera i osobnej bazy wektorowej.

Założenia, nie pomiar Jev: 1 USD = 4 zł; +5% ponowień; bez VAT i darmowych limitów. LLM: Gemini 2.5 Flash-Lite; wektory/rerank: Voyage [S4–S7].

100 tys. sesji: około 49–80 zł za API w wariantach z Jev

Sesje / miesiąc	Dziś: Qwen	Tylko tańszy LLM	Jev + lokalnie	Jev + semantyka
10 000	60 zł	13 zł	5 zł	8 zł
100 000	597 zł	126 zł	49 zł	80 zł
1 000 000	5 974 zł	1 260 zł	494 zł	803 zł
10 000 000	59 739 zł	12 600 zł	4 939 zł	8 026 zł

Sesja = jedna potrzeba + doprecyzowania. Założenie: średnio 1,5 kroku AI na sesję.
100 tys. sesji to np. 50 tys. użytkowników po 2 wyszukiwania miesięcznie.

AI to tylko część kosztu utrzymania

Scenariusz miesięczny, PLN netto. Rezerwy są założeniem do pilotażu, nie ofertą dostawcy.

Składnik	10 tys. sesji	100 tys. sesji	1 mln sesji
Hosting, baza, kopie, monitoring	350	750	2 500
Obsługa: 150 zł/h	600 (4 h)	1 800 (12 h)	6 000 (40 h)
Rezerwa AI innych modułów	100	300	1 500
Matchmaking: Jev + semantyka	8	80	803
Razem przed rezerwą	1 058	2 930	10 803
Budżet z rezerwą 20% ≈	1 270 zł	3 520 zł	12 970 zł

Budżet pilotażu z poprzedniej wersji: 1 100 zł. Teraz skala i rezerwa są jawne.
Poza sumą: rozwój funkcji, audyty, migracje oraz praca merytoryczna ROPS.

Obsługa i infrastruktura: szacunek autorski. AI kreatora, testera i adaptacji nie było mierzone; rezerwę trzeba zastąpić osobnym pomiarem.

Mieszkaniec też może zacząć sam.

CEL PROJEKTOWY

WCAG

2.1 AA

Bez znajomości
urzędowego języka.



01 Prosty język

Jasne etykiety i wskazówki w formularzu.

02 Klawiatura

Widoczny fokus i logiczna kolejność przejścia.

03 Czytniki ekranu

Nazwane pola, statusy i komunikaty błędów.

04 Czytelny układ

Kontrast, powiększenie i wąski ekran.

ŁĄCZNIK

Marta zaczyna od swoich seniorów. Jej pomysł może pomóc dalej.

Poznaje innowacje. Tworzy własną.
Testuje ją z ludźmi.
Cel: wdrożenia w kolejnych gminach.

Lokalny pomysł.
Wartość dla całego regionu.

Demo: [\[link zespołu\]](#)
Makiety UX/UI: [\[link zespołu\]](#)



Sześć prób pokazuje koszt krótkich zapytań

Próba	Tokeny in	Tokeny out	API, USD	Czas
Krótki opis seniorów	861	117	0.0005296	2.20 s
Konkretny opis pomocy	879	122	0.0005483	1.97 s
Ogólna potrzeba	858	120	0.0005391	1.85 s
Opis + 1 odpowiedź	882	116	0.0005223	1.72 s
Opis + 2 odpowiedzi	920	113	0.0005101	2.74 s
Opis + 3 odpowiedzi	960	138	0.0006196	2.17 s

Średnio: 0.0005448 USD ≈ 0,00218 zł / wywołanie przed opłatą platformy.
Cały pomiar: 0,003269 USD. Dostawca: Wafer, model qwen/qwen3.8-27b.

Wycena jest policzalna i możliwa do aktualizacji

Model / usługa	USD / 1 mln in	USD / 1 mln out
Qwen3.8 27B / Wafer	0,024	4,35
Jev 1.13 / TypeSafe	0,042	0
Gemini 2.5 Flash-Lite	0,10	0,40
Voyage-4-lite / rerank-3-lite	0,02 / 0,02	nie dotyczy

C = liczba sesji × koszt kroków × 1,05 × 4 zł/USD

Qwen i wariant „tylko tańszy LLM”: 1 200 in + 200 out / krok, 1,5 kroku / sesję.

Qwen: dodatkowo 5,5% OpenRouter. Nie zakładamy zniżek za cache.

1,5 kroku = 100% pierwszych wyszukiwań + 30% rund 1 + 15% rund 2 + 5% rund 3.

Jev: 800 tokenów obejmuje stan, pytania i etykiety. Nie został przetestowany na tej aplikacji.

Reranker: 20 × (200 tokenów pytania + 250 tokenów dokumentu) = 9 000 tokenów.

Skalowanie wymaga limitów i testu ruchu szczytowego

Sesje / miesiąc	Średnio kroków / s	Szczyt × 20
100 000	0.06	1.2 / s
1 000 000	0.58	11.6 / s
10 000 000	5.79	115.7 / s

Przed uruchomieniem

Wspólny limit dla wszystkich instancji, limity sesji i limit miesięczny wydatków. Krótka kolejka; maksymalnie jedno automatyczne ponowienie.

W trakcie działania

Mierzymy koszt sesji, p95 czasu, liczbę pytań, udział eskalacji i trafność top 3. Po wyczerpaniu budżetu działa wyszukiwanie i uzasadnienie lokalne.

Miesiąc = 30 dni; mnożnik szczytu 20 jest założeniem. Jev publikuje 80 req/s i 100k tok/s, ale limity są zmienne; 10 mln wymaga uzgodnienia pojemności [S4].

Najpierw jakość i pomiar. Potem więcej modułów

Zmiana względem modelu bazowego	API / 100 tys. sesji
Jev + semantyka: 10% eskalacji, 20% uzasadnień	80 zł
Uzasadnienie generowane w każdej sesji	145 zł
40% eskalacji + uzasadnienie w każdej sesji	181 zł
Qwen: 4 kroki × 3 500 in / 2 000 out (stres)	15 569 zł

ETAP 1

Porównaj tańszy LLM z Jev na 200–500 polskich opisach. Oceń trafność top 3, fałszywe odrzucenia i pytania.

ETAP 2

Semantyka tylko po wykazaniu lepszych wyników. Cały wariant Jev z semantyką oszczędza ok. 46 zł na 100 tys. sesji wobec samej zmiany LLM.

Stres to ilustracja zużycia blisko limitu odpowiedzi, nie prognoza. Kurs i wszystkie stawki mogą się zmienić. Confidence Jev nie jest gwarancją trafności po polsku [S4, S8].

Źródła, data i granice oszacowania

- S1** **Lokalny stan roboczy, baza 0b4d5b4; interpreter, ranking, pytania i kontrakt API**
apps/api/src/modules/matchmaking/ oraz packages/api-contracts/src/matchmaking.schema.ts
- S2** **OpenRouter: Qwen3.8 27B, dostawca Wafer**
<https://openrouter.ai/qwen/qwen3.8-27b>
- S3** **OpenRouter: opłata Standard 5,5%**
<https://openrouter.ai/pricing>
- S4** **TypeSafe: Jev 1.13, cena, języki i limity**
<https://docs.typesafe.ai/models>
- S5** **Vercel: Jev oraz zasady naliczania kosztu**
<https://vercel.com/ai-gateway/models/jev>
- S6** **Google: Gemini 2.5 Flash-Lite, płatne API Standard**
<https://ai.google.dev/gemini-api/docs/pricing>
- S7** **Voyage: embedding i reranker, tokeny query × liczba dokumentów**
<https://docs.voyageai.com/docs/pricing>
- S8** **TypeSafe: interpretacja confidence i dobór progów**
<https://docs.typesafe.ai/confidence>

Stan na 04.10.2026. Dane cenowe: dokumentacja dostawców. Wolumeny, proporcje ruchu, praca i infrastruktura: założenia planistyczne. Nie zmieniono kodu aplikacji.

Polityka Vercel: vercel.com/academy/ai-gateway/ai-gateway-pricing. Zrzut pomiaru i obliczenia zachowane w materiałach roboczych analizy.